Année 2025–2026



UNIVERSITÉ
DE GENÈVE

FACULTÉ DES SCIENCES
Département d'informatique

Projet de Bachelor d'informatique

SOM : Self-Organizing Maps

William Guillermo Calero Roncal

Année 2025–2026

Table des matières

1 Introduction **2**
- 1.1 Contexte . . . 2
  - 1.1.1 Neurone artificiel . . . 2
  - 1.1.2 Neurone du SOM . . . 3
- 1.2 Objectifs du projet . . . 4

2 État de l'art **5**
- 2.1 Self-Organizing Maps (SOM) . . . 5
  - 2.1.1 Quantification vectorielle (VQ) . . . 5
  - 2.1.2 SOM de base . . . 6
  - 2.1.3 Batch SOM . . . 8
- 2.2 Limites . . . 11
  - 2.2.1 Quantification vectorielle et reduction de dimension . . . 12
  - 2.2.2 Autres limitations . . . 13
- 2.3 Extensions . . . 14
  - 2.3.1 Accelerating Stochastique K-SOM . . . 14
  - 2.3.2 FlowSOM . . . 15
  - 2.3.3 SOM Hybrides . . . 16
  - 2.3.4 Autres extensions . . . 17
- 2.4 Deep embedded self-organizing maps (DESOM) . . . 17
  - 2.4.1 Autoencodeur (AE) . . . 18
  - 2.4.2 Architecture du DESOM . . . 19
  - 2.4.3 Fonction de perte du DESOM . . . 19
  - 2.4.4 Processus d'apprentissage . . . 21

3 Etude empirique **24**
- 3.1 Données utilisées . . . 24
- 3.2 SOM de base . . . 24
- 3.3 DESOM . . . 24
- 3.4 Comparaison et analyse des résultats . . . 24

4 Conclusion **25**

Chapitre 1

Introduction

Durant les dernières décennies, plusieurs méthodes d'apprentissage automatique ont fait leur apparition. Cela s'est produit grâce à une croissance exponentielle des données récoltées avec lesquelles nous tentons de répondre à des questions dans plusieurs domaines. Plusieurs méthodes s'inspirent directement du cerveau humain et une d'entre elles se nomme les cartes auto-organisées (self organizing-maps : SOM). Cette méthode s'inspire directement des brain maps. Certaines cellules du cerveau répondent de manière sélective à un stimulus sensoriel spécifique et ces cellules ont tendance à s'assembler formant une topographie particulière en fonction du stimulus spécifique [7]. Les SOM permettent la projection des données de grande dimension dans une grille à petite dimension tout en essayant de préserver leur topologie locale en tenant compte de leur voisinage.

1.1 Contexte

Actuellement, les réseaux de neurones ont une place centrale dans le domaine de l'apprentissage automatique. Insipirée aussi des neurones biologiques, des cellues nerveuses dont la fonction est de agréger et transmettre des informations via des sigaux chimiques et électriques [12], ces modèles consistent à former des interconnexions entre couches des neurones artificiels.

Dans la littérature, nous observons une tendance à appeler les SOM des réseaux de neurones. Cependant, certaines différences remarquables entre les réseaux de neurones au sens du perceptron et les cartes auto-organisées existent. Afin de clairifier ces distinctions, nous allons rappeler la définition d'un neurone artificiel dans les réseaux de neurones classiques, puis nous comparerons ce modèle avec le "neurone" d'un SOM.

1.1.1 Neurone artificiel

Un neurone artificiel ou plus communément un neurone formel est une représentation d'une combinaison linéaire suivie d'une fonction d'activation [10]. Pour un neurone k, considérons $m+1$ entrées $x_0, \ldots, x_m$ et des poids associés $w_{k0}, \ldots, w_{km}$. Généralement, x_0 est une entrée de biais qui est fixée à 1. Son fonctionnent commence par une somme pondérée de ses entrées :

$$a_k = \sum_{i=0}^{m} w_{ki} x_i$$

À cela, une fonction d'activation $\varphi(.)$ [13] est appliqué pour avoir la sortie du neurone :

$$\hat{y}_k = \varphi(a_k)$$

Cette valeur va devenir l'entrée de la couche suivante (si ce n'est la dernière). Les réseaux de neurones, qui ont ce type de neurones et au moins une couche cachée, sont entrainés à travers une fonction de coût $\mathcal{L}$ (loss function) dont le but est de la minimiser. Cette correction est réalisée à travers un algorithme d'optimisation tel que la descente de gradient (gradient descent) appelé "Backpropagation" dans ce domaine [10]. L'agorithme réduit les erreurs de prédiction entre $\hat{y}_k$ et y_k en ajustant les poids w_{ki}. Dans ce contexte, nous avons un apprentissage supervisé, car la fonction se repose sur la connaissance des labels y_k. Ainsi, un neurone artificiel est une analogie qui interprète mathématiquement le fonctionnement d'un neurone avec des méthodes d'apprentissage du machine learning (apprentissage automatique).

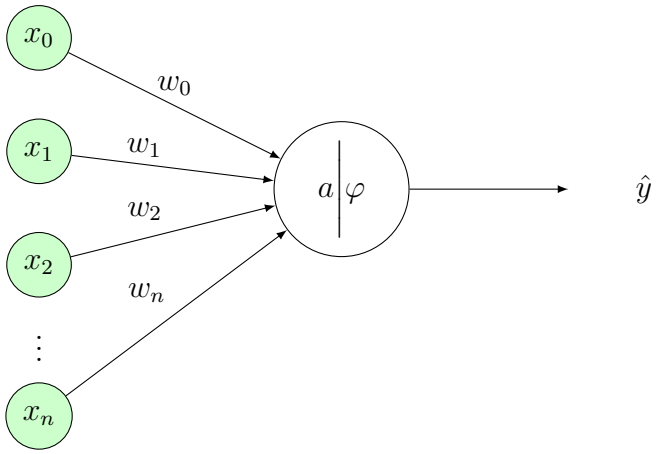


FIGURE 1.1 – Neurone formel

Dans ce contexte, le but du réseau de neurones est d'approximer une fonction de prédiction du type $y = \phi(x)$ par une fonction ϕ_θ represenntée par le réseau et paramétrée par $\theta = [w_{ij}^k]$ l'ensemble des poids.

Le document d'approximatio universelle montre que cela est possible avec un certain niveau d'approximation [4].

1.1.2 Neurone du SOM

Par contraste, étant donné un ensemble de données d'entrée,

un "neurone" d'un SOM est un vecteur prototype représentant une région de l'espace des données. Il est associé à un vecteur de poids $w_i \in \mathbb{R}^d$ de même dimension que les données d'entrée $x \in \mathbb{R}^d$. Son vecteur de poids est mis à jour en fonction de la distance entre les données d'entrée et son vecteur de poids.

Le neurone S_c qui est le plus proche de la donnée d'entrée est appelé *Best Matching Unit* (BMU), associé au vecteur de poids w_c, et c'est lui qui est mis à jour ainsi que ses voisins en fonction de la formule suivante :

$$w_i(t+1) = w_i(t) + h_{ci}(t)[x(t) - w_i(t)]$$

Où, $h_{ci}(t)$ est la fonction de voisinage qui diminue avec la distance entre le neurone S_i et le BMU S_c, ainsi que du temps t [7].

Dans ce contexte, nous avons un apprentissage dit non supervisé et compétitif, car les "neurones" sont en compétition pour représenter les données d'entrée, et sans labels pour guider l'apprentissage. Cela est une différence fondamentale avec les neurones formels, car les SOM sont utilisés pour la visualisation et la réduction de la dimensionnalité, tandis que les neurones formels sont utilisés plutôt pour la classification et la régression. De plus, les SOM préservent la topologie des données d'entrée, c'est-à-dire qu'ils conservent les relations de voisinage dans la projection de l'espace à dimension réduite, ce qui n'est pas le sujet pour les neurones formels. Nous remarquons également une différence dans la fonction de coût, elles n'ont pas la même finalité. Les SOM utilisent une fonction de coût basée sur la minimisation d'une mesure de distance entre les données d'entrée et les prototypes, tandis que les neurones formels ont une fonction de coût basée sur l'erreur de prédiction. Donc, la fonction de coût d'une carte auto-organisées ne produit pas de manière explicite de sortie ou de prédiction.

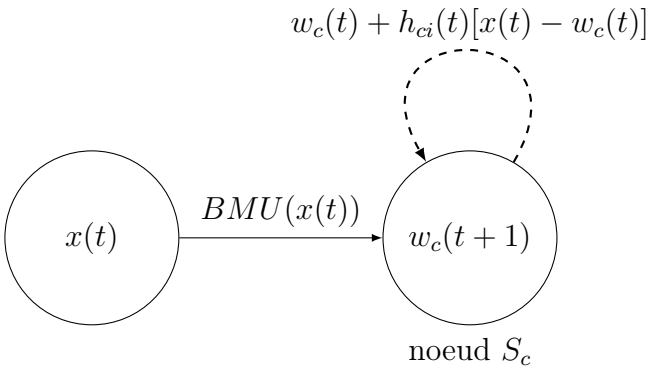


FIGURE 1.2 – Noeud d'un SOM

Dans la suite nous ferons l'analogie entre les noeuds S_i et le vecteur de poids w_i qu'il porte.

Même s'ils partagent une inspiration biologique commune, les SOM présentent des caractéristiques uniques qui les distinguent des réseaux de neurones traditionnels. Ainsi, même si historiquement les cartes auto-organisées sont classées comme des réseaux de neurones, par les différences que nous avons citées, il est raisonnable de les considérer comme des structures différentes.

Par la suite de ce rapport et pour éviter toutes confusions, nous allons utiliser "noeud" pour les unités de calcul d'un SOM.

1.2 Objectifs du projet

L'objectif de ce projet consiste à comprendre les cartes auto-organisées, leurs limites ainsi que les extensions proposées dans la littérature pour y remédier. Dans la suite de ce rapport, un état de l'art sur les SOM sera présenté. Ensuite, nous ferons une étude empirique en modélisant et implémentant un SOM de zéro et en comparant avec un SOM d'une bibliothèque existante ainsi qu'avec l'extension DESOM. Enfin, nous analyserons et discuterons de leurs performances, afin de mettre en évidence leurs avantages et inconvénients.

Chapitre 2

État de l'art

2.1 Self-Organizing Maps (SOM)

Les cartes auto-organisées ont été introduites par Teuvo Kohonen en 1982 [3]. Ce modèle se base sur une approche d'apprentissage compétitive. Il s'agit d'une forme d'apprentissage non supervisé où chaque nœud "compétent" représente une région de l'espace des données d'entrée. Ce type d'apprentissage est utilisé notamment pour le clustering sous le nom de quantification vectorielle.

2.1.1 Quantification vectorielle (VQ)

La quantification vectorielle (VQ) est une technologie utilisée surtout dans le traitement moderne de la numérisation des signaux [7]. Elle consite à partitionner en régions distinctes et contiguës dont chacune est représentée par un vecteur. Dans cette méthode, les données d'entrées fonctionnent comme des features qui sont représentées dans un espace fini par d'autres vecteurs de même dimension. Cet ensemble de vecteurs se nomme codebook. Une VQ s'interprète de la manière suivante : Soit $x \in \mathbb{R}^d$ une donnée d'entrée et soit le codebook avec w_i vecteurs de même dimension et w_c, le vecteur gagnant (apprentissage compétitif), le plus proche de x [6].

$$c(x) = \arg\min_i ||x - w_i||^2$$

Admettons que $p(x)$ soit la densité de probabilité de x sur V, alors l'erreur moyen de la quantification E est définie par :

$$\mathcal{E} = \int_V ||x - w_{c(x)}||^2 p(x) dV$$

où V est l'espace d'entrée et donc dV est le volume différentiel. La fonction E est une fonction d'energie qui peut être minimisée par l'algorithme de descente de gradient [7]. Par simplification, nous avons pris une distance euclidienne, mais d'autres mesures de distance peuvent être utilisées. La variante que nous avons présentée est connue sous le nom de "k-means" [7].

Dans la pratique, $p(x)$ est inconnue, mais nous avons un ensemble de données $\{x_i \in \mathbb{R}^d\}_{1 \leq i \leq n}$. Pour avoir une estimation de E, il faut approximer $p(x)$ par une distribution empirique à partir de l'ensemble de données. Donc, nous avons :

$$p(x) \approx \frac{1}{n} \sum_{i=1}^{n} \delta(x - x_i)$$

Où la fonction δ est la fonction de Dirac concentrant la densité de probabilité en un point [14] :

$$\delta(x) = \begin{cases} \infty & \text{si } x = 0 \\ 0 & \text{sinon} \end{cases}$$

La particularité de cette fonction qui nous intéresse est la suivante [14] :

$$\int_{-\infty}^{\infty} f(x)\delta(x - a)dx = f(a)$$

En supossons que $f(x) = ||x - w_{c(x)}||^2$, alors nous avons :

$$\mathcal{E} \approx \int_V f(x) \frac{1}{n} \sum_{i=1}^{n} \delta(x - x_i)dV \Leftrightarrow$$

$$\mathcal{E} \approx \frac{1}{n} \sum_{i=1}^{n} \int_V f(x)\delta(x - x_i)dV = \frac{1}{n} \sum_{i=1}^{n} f(x_i) \Leftrightarrow$$

$$\mathcal{E} \approx \frac{1}{n} \sum_{i=1}^{n} ||x_i - w_{c(x_i)}||^2$$

Ainsi, la quantification vectorielle minimise l'énergie $\mathcal{E}$ en associant chaque donnée d'entrée a son prototype (BMU) le plus proche. Les SOM suivent cette même approche d'apprentissage compétitive. Cependant, contrairement à la VQ classique, les SOM imposent une topologie sur les prototypes (la grille), de manière à ce que les prototypes voisins dans la grille soient aussi proches dans l'espace des données d'entrée.

2.1.2 SOM de base

Les SOM créent une structure qui préserve la topologie locale dans un voisinage défini. Ce "calibrage" ou mise à jour des noeuds voisins dépend du Best Matching Unit(BMU), le noeud gagnant, et du temps t [6]. Les cartes auto-organisées ne dérivent pas de manière explicite d'une fonction de coût globale, mais d'une règle de mise à jour locale qui est appliquée à chaque noeud en fonction de sa proximité avec le BMU.

Soit un ensemble de données d'entrée $\{x_i \in \mathbb{R}^d\}_{1 \leq i \leq n}$ et un codebook $\{w_i \in \mathbb{R}^d\}_{1 \leq i \leq m}$. Le BMU suit le même principe que celui de la VQ, c'est à dire le noeud le plus proche d'un certain x :

$$c = \arg\min_i ||x - w_i||^2$$

$$BMU(x) = w_c$$

L'entier c représente l'indice du noeud gagnant pour les donnée x. En partant de la quantification vectorielle, l'équation de mise à jour d'un noeud w_i est la suivante [6] :

$$w_i(t+1) = \begin{cases} w_i(t) + \alpha(t)[x(t) - w_i(t)] & \text{si } i = c \\ w_i(t) & \text{sinon} \end{cases}$$

Où $\alpha(t)$ est le taux d'apprentissage qui diminue avec le temps t. Nous observons que dans cette formule, seul le noeud gagnant est mis à jour, il est "attiré" vers la donnée d'entrée. Dans le VQ classique, seulement le noeud gagnant est mis à jour et sans interaction avec ses voisins. Cependant, dans les SOM, les noeuds voisins du BMU sont aussi mis à jour.

Admettons l'ensemble de noeuds voisins du BMU $N_c(t)$ qui décroit avec le temps, alors la formule de mise à jour devient [6] (le BMU fait partie de $N_c(t)$) :

$$w_i(t+1) = \begin{cases} w_i(t) + \alpha(t)[x(t) - w_i(t)] & \text{si } w_i \in N_c(t) \\ w_i(t) & \text{sinon} \end{cases}$$

Avec cette nouvelle approche, les noeuds voisins du BMU sont aussi mis à jour. Cependant, le taux de mise à jour pour les noeuds voisins est la même que celui du BMU, ce qui peut poser des problèmes de convergence, des transitions plus brusques qui peuvent provoquer des cartes moins lisses et organisées. Donc nous dégradons la propriété la plus importante des SOM qui est la préservation de la topologie locale.

Un choix plus standard et efficace est de prendre la fonction gaussienne de voisinage $h_{ci}(t)$ qui diminue avec la distance entre le noeud w_i et le BMU w_c ainsi que du temps t [7] :

$$h_{ci}(t) = \alpha(t) e^{-\frac{||idx(w_c) - idx(w_i)||^2}{2\sigma(t)^2}}$$

Où $idx(w_c)$ et $idx(w_i)$ sont les indices de position du BMU et du noeud w_i dans la grille. Donc, nous avons $h_{cc}(t) = \alpha(t) \, \forall t$. La fonction $\sigma(t)$ est le calcul du rayon de voisinage qui diminue avec t et qui contrôle l'étendue de la mise à jour des noeuds voisins. Elle peut être définie de la manière suivante, avec T le nombre total d'itérations [3] :

$$\sigma(t) = \sigma_0 e^{-\frac{t}{T}}$$

Donc, la distance entre les noeuds dans la grille influence la mise à jour, plus un noeud est éloigné du BMU, moins il sera mis à jour. Cette approche permet d'avoir des cartes plus lisses et organisées avec des transitions plus douces.

Cela nous mène à la formule de mise à jour finale d'un noeud w_i dans un SOM :

$$w_i(t+1) = w_i(t) + h_{ci}(t)[x(t) - w_i(t)]$$

Nous pouvons aussi interpréter la mise à jour en deux termes de variation de poids. Pour le noeud gagnant (BMU) :

$$\Delta w_c(t) = h_{cc}(t) \, [x(t) - w_c(t)] = \alpha(t) \, [x(t) - w_c(t)]$$

Pour un noeud voisin w_i :

$$\Delta w_i(t) = h_{ci}(t) \, [x(t) - w_i(t)]$$

Ainsi, la mise à jour des poids peut s'écrire de manière équivalente :

$$w_i(t+1) = w_i(t) + \Delta w_i(t)$$

De manière plus schématique, nous avons la figure 2.1 qui illustre la mise à jour d'un noeud w_i en fonction du BMU w_c et de la distance entre eux dans la grille.

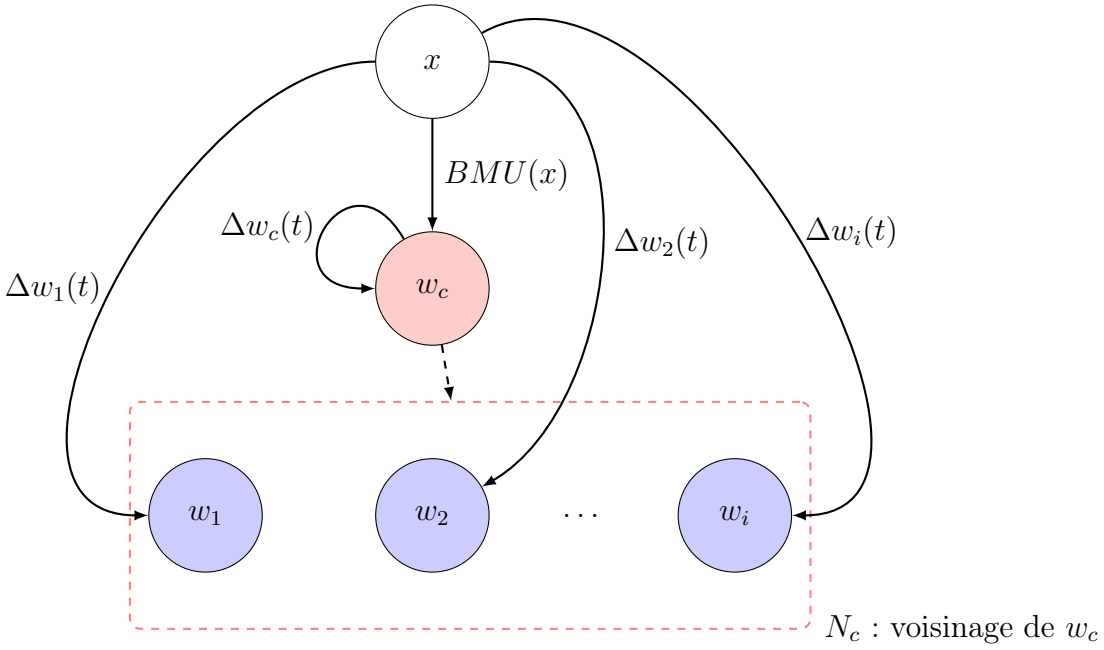


FIGURE 2.1 – Mise à jour des noeuds voisins $w_1, w_2, \ldots, w_i$ en fonction du BMU w_c et de la distance dans la grille

Cela nous donne une première idée d'algorithme d'apprentissage :

Algorithm 1 Algorithme d'apprentissage d'un SOM (stepwise)

Initialiser les poids w_i de manière aléatoire ou avec PCA
Initialiser le taux d'apprentissage $\alpha(0)$ et la largeur de voisinage $\sigma(0)$
Définir le nombre d'itérations maximum T
for $t = 1$ **à** T **do**
    Sélectionner un échantillon d'entrée $x(t)$
    $c = \arg\min_i ||x(t) - w_i||^2$ ▷ indice du BMU
    $\alpha(t) = \alpha(0) \cdot e^{-t/T}$ ▷ décroissance du taux d'apprentissage
    $\sigma(t) = \sigma(0) \cdot e^{-t/T}$ ▷ décroissance de la largeur de voisinage
    for tous les noeuds i **do**
        $h_{ci}(t) = \alpha(t) \cdot e^{\left(-\frac{\|c-i\|^2}{2\sigma(t)^2}\right)}$ ▷ calcul de la fonction de voisinage
        $w_i(t+1) = w_i(t) + h_{ci}(t) \cdot [x(t) - w_i(t)]$ ▷ mise à jour du poids du noeud i
    end for
end for

Ainsi, nous avons présenté les étapes de l'agorithme d'apprentissage d'un SOM de manière détaillée. Neanmoins, il existe un autre variante plus efficace en pratique appelée *batch SOM* [6].

2.1.3 Batch SOM

Batch SOM est une variante du SOM classique qui diffère de l'approche stepwise présentée précédemment. Au lieu de mettre à jour les poids à partir d'un seul échantillon

à chaque itération, elle utilise l'ensemble des données d'entrée. Cette approche permet la parallélisation des calculs, ce qui peut accélérer la convergence, notamment pour les grands ensembles de données [7].

Nous partons de la supposition que la convergence vers un état stable d'un SOM existe [7]. Nous avons quelques exigences pour que cela soit possible :

— lorsque $t \to \infty$, alors l'espérance de $w_i(t)$ est égale à l'espérance de $w_i(t+1)$
— $h_{ci} \neq 0$
— c est l'indice du BMU pour $x(t)$

Cela peut être vu comme la recherche d'un point fixe des poids w_i, où les mise à jour sont en moyenne nulles. Nous pouvons l'écrire avec E_t l'opérateur d'espérance sur t [7] :

$$\forall i, \quad E_t(h_{ci}[x(t) - w_i(t)]) = 0$$

Remarquons que $w_i(t)$ est indépendant de t lorsque $t \to \infty$, nous allons le noter w_i^*. Si l'espérance E_t est calculée à partir de la distribution empirique des données d'entrée, alors nous avons (pour un horizon T) :

$$E_t(h_{ci}(t)[x(t) - w_i^*]) = \frac{1}{T}\sum_{t=1}^{T} h_{ci}(t)[x(t) - w_i^*] = 0$$

En développant cette expression, nous obtenons :

$$\frac{1}{T}\sum_{t=1}^{T} h_{ci}(t)[x(t) - w_i^*] = 0 \Leftrightarrow$$

$$\sum_{t=1}^{T} h_{ci}(t)x(t) - w_i^* \sum_{t=1}^{T} h_{ci}(t) = 0 \Leftrightarrow$$

$$w_i^* = \frac{\sum_{t=1}^{T} h_{ci}(t)x(t)}{\sum_{t=1}^{T} h_{ci}(t)}$$

L'expression actuelle peut être écrite en regroupant leur BMU. Soit C_j l'ensemble des données dont le BMU est w_j, n_j le nombre de points dans ce groupe, et $x_{w,j}$ la moyenne de ces points. Alors, la mise à jour peut s'écrire [7] :

$$w_i^* = \frac{\sum_j h_{ji}\, n_j\, x_{w,j}}{\sum_j h_{ji}\, n_j}$$

Avec cette nouvelle interprétation, chaque noeud w_i est mise à jour comme une moyenne pondérée des données qui lui sont associées. Nous avons donc une première approche de comment batch SOM fonctionne. Comme déjà mentionné, cette variante traite l'ensemble des données d'entrée à chaque itération et pour cela les noeuds du SOM sont associés à une liste des copies des $x(t)$ dont ils sont le BMU [7]. Schématiquement, la figure 2.2 illustre la mise à jour des noeuds dans le batch SOM.

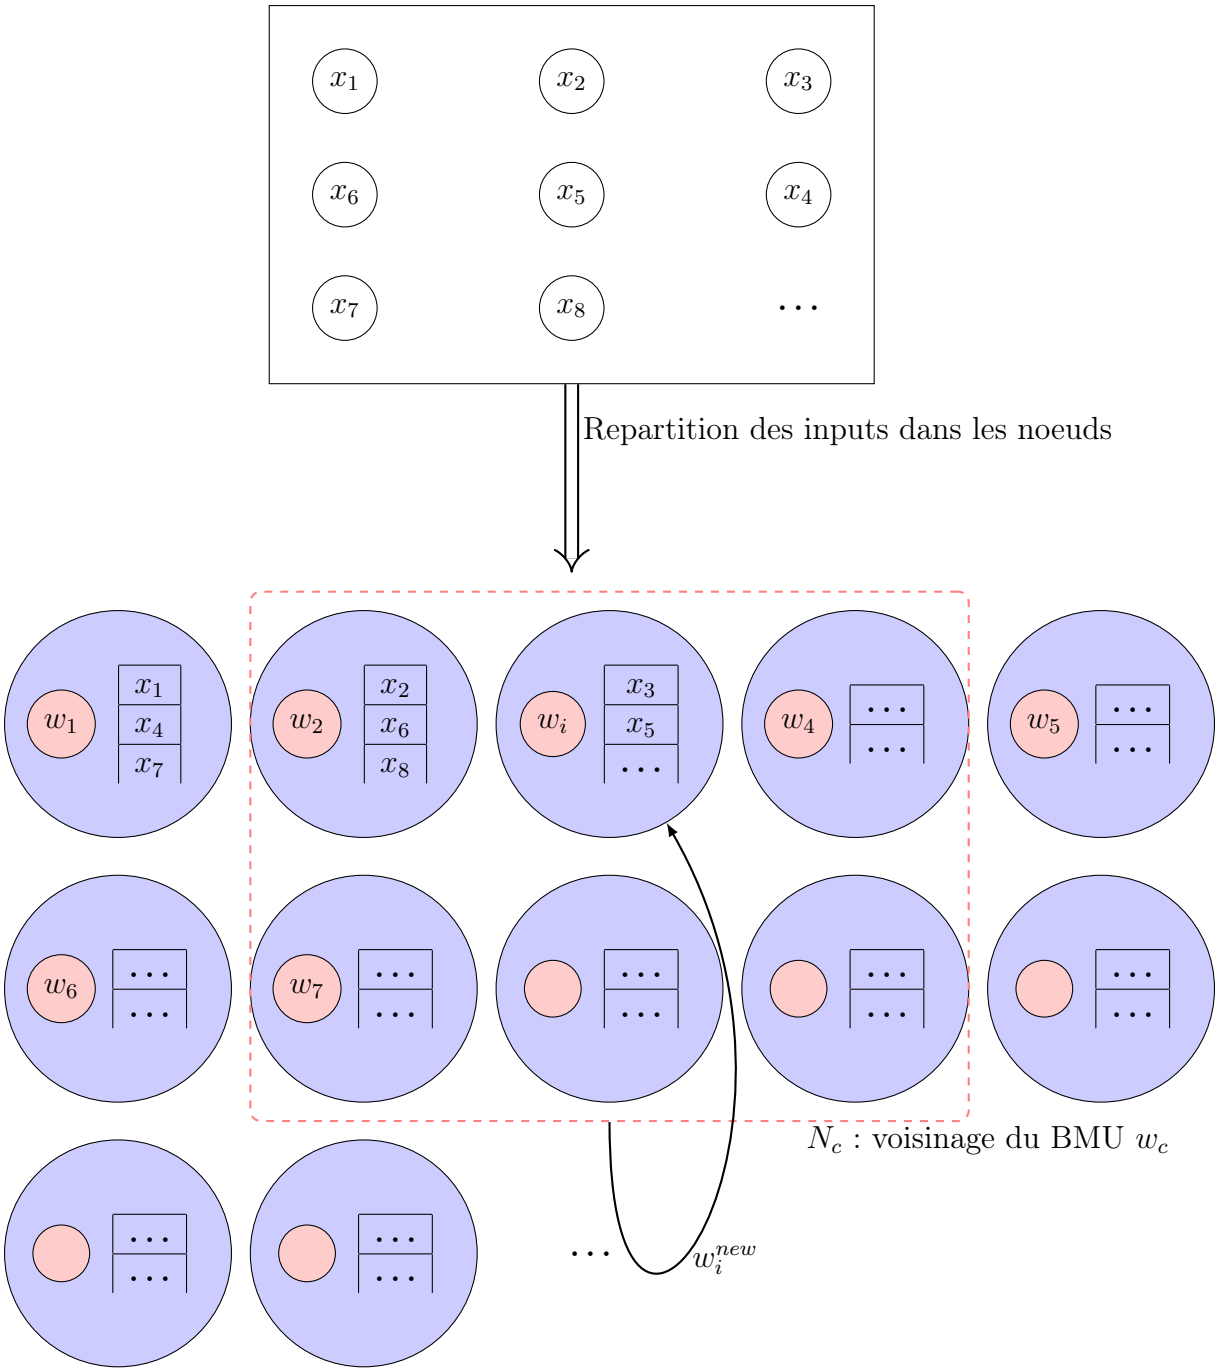


FIGURE 2.2 – Illustration du fonctionnement du batch SOM. Les données d'entrée sont associées à leur BMU, puis les prototypes sont mise à jour comme des moyennes pondérées des données, en tenant compte de la fonction de voisinage.

L'algorithme suit l'idée présentée dans la figure 2.2. Nous avons une notions de regroupement de données pour chaque noeud. L'implémentation est faite à l'aide d'un dictionnaire qui associe au noeud w_j l'ensemble $C_j = \{x_i \in \mathbb{R}^d : BMU(x_i) = w_j\}$. L'algorithme d'apprentissage du batch SOM est présenté dans l'algorithme 2, où la

fonction de voisinage est définie par :

$$h_{ji}(t) = \exp\left(-\frac{\|idx_j - idx_i\|^2}{2\sigma(t)^2}\right)$$

Algorithm 2 Algorithme d'apprentissage d'un batch SOM

Initialiser les poids w_i de manière aléatoire ou avec PCA
Initialiser $\sigma(0)$
Définir T le nombre d'itérations maximum
for $t = 1$ **à** T **do**
    nodes = {} ▷ Dictionnaire pour stocker les données associées à chaque noeud
    $\sigma(t) = \sigma(0)e^{-t/T}$ ▷ Calcul de la largeur de voisinage
    for chaque x_i dans les données **do**
        $c = \arg\min_j \|x_i - w_j\|^2$
        nodes[c].append(x_i) ▷ Ajouter x_i à la liste des données associées au noeud w_c
    end for
    for chaque noeud j **do**
        $x_{w,j} = mean(nodes[j])$ ▷ Moyenne des données dans C_j
        $n_j = len(nodes[j])$ ▷ Nombre de données dans C_j
    end for
    for chaque noeud i **do**
        calculer $h_{ji}(t)$ pour tout j
        $w_i(t+1) = \frac{\sum_j h_{ji}(t)\, n_j\, x_{w,j}}{\sum_j h_{ji}(t)\, n_j}$ ▷ Mise à jour du poids du noeud i
    end for
end for

Ainsi, cette variante a pu être construite à partir de l'hypothèse de convergence d'un SOM vers un état stable. Elle permet une convergence plus rapide, surtout pour les grands ensembles de données, et se prête naturellement à la parallélisation. Dans la littérature, Kohonen souligne également que le batch SOM peut aussi être généralisée pour des données d'entrée non vectorielles, à condition de disposer d'une mesure de distance entre les données d'entrée et les noeuds du SOM [7].

Enfin, nous avons présenté deux variantes d'apprentissage pour un SOM classique : la version stepwise et la version batch. Cependant, malgré ses avantages, le batch SOM présente certaines limites, notamment en termes de complexité computationnelle et de mémoire requise [3].

2.2 Limites

Les cartes auto-organisées possède la capacité de réaliser simultanément une quantification vectorielle et un reduction de dimension. Cependant, certains travaux on montré que, du point de vue de l'erreur de la quantification ou de la préservation des distances, les SOM peuvent être moins performant que la combinaison de deux méthodes spécialisées [1]. En particulier, l'association d'une méthode de quantification vectorielle telle que le k-means, suivie d'une technique de reduction de dimension comme le Sammon mapping, permet d'optimiser séparément ces deux objectifs.

Cette différence s'explique par le fait que les méthodes utilisées dans une approche séquentielle sont chacune conçues pour minimiser explicitement une fonction de coût spécifique, tandis que les SOM réalisent simultanément ces tâches à travers un mécanisme unique d'apprentissage. Ce couplage induit un compromis entre la qualité de la quantification et celle de la projection, pouvant conduire à des performances inférieures sur chacun de ces aspects pris individuellement.

Dans le cas de la quantification vectorielle, la méthode k-means a tendance à produire des performances meilleures que les SOM. En effet, k-means est spécifiquement conçu pour minimiser la distance intra-cluster, tandis que les SOM doivent également satisfaire une contrainte d'organisation topologique. Cela limite la capacité de répresentation des structures de données complexes, en particulier lorsque nous avons un nombre plus élevé de clusters [1].

Concernant la reduction de dimension, les technique traditionnellles ont tendance à mieux préserver les distances entre les points de données, tandis que les SOM peuvent introduire des distorsions dans la représentation des distances à cause de leur structure en grille et de la manière dont ils mettent à jour les poids. Cela s'accentue particulièrement avec l'augmentation de dimensionnalité des données d'entrée.

2.2.1 Quantification vectorielle et reduction de dimension

Une des méthodes les plus courantes pour la quantification vectorielle est le k-means, qui est un algorithme de clustering qui partitionne les données en k clusters en minimisant la somme des distances au carré entre les points de données et les centres de cluster. Cette méthode a été déjà mentionnée dans la section 2.1.1. Contrairement au k-means, qui attribue simplement chaque observation à un centroïde, le SOM organise ses prototypes sur une grille. Cette structure permet de projeter les données sur une carte de prototypes, où la proximité entre nœuds cherche à refléter les similarités entre les données. Donc, pour les SOM, le codebook est organisé sur une grille régulière cela induit une contrainte sur la manière dont les poids sont mis à jour. Il est également important de savoir que lorsque la fonction de voisinage $h_{ci} \to 0$, l'algorithme SOM se comportent de manière similaire au k-means, car seul le BMU est mis à jour[7].

Un reduction de dimension, pour être plus précis, est une transformation $\Phi : \mathbb{R}^n \to \mathbb{R}^m$ qui préserve les similarités ou distances dans l'espace de départ lors de la projection dans $\mathbb{R}^m$. Il existe plusieurs techniques de reduction de dimension, chacune avec ses propres avantages et inconvénients. Par exemple, le Sammon mapping, le Umap, tsne ou encore les cartes auto-organisées. Le sammon mapping, en pariculier, permet la reduction de dimension en minimisant la fonction de coût qui pondère les différences de distances entre les points de données et leurs projections. Cela est optimisé par la méthode de la decente de gradient [1]. Soit d_{ij} la distance entre les points x_i et x_j dans l'espace d'origine, et $\hat{d}_{ij}$ la distance entre leurs projections $\Phi(x_i)$ et $\Phi(x_j)$ dans l'espace réduit. La fonction de coût s'écrit :

$$\frac{1}{\sum_{i=0}^{n-1}\sum_{j<i} d_{ij}} \sum_{i=0}^{n-1}\sum_{j<i} \frac{(d_{ij} - \hat{d}_{ij})^2}{d_{ij}}$$

Enfin, il est important de remarquer que le codebook d'un SOM est limité en nombre de noeuds, cela entraine une discrétisation de l'espace d'entrée, ce qui peut conduire à une perte d'information si le nombre de noeuds est insuffisant et à une représentation moins précise des données [1].

Dans [1], nous trouvons une approche qui consiste à faire d'abord une quantification vectorielle avec le k-means, puis à appliquer une reduction de dimension avec le Sammon mapping. Les performances de cette approche sont comparées à celles des SOM pour différentes configurations, comme illustré dans le tableau 2.1.

algorithm	no. clusters	dimension	msqe	Rand	corr.
SOM	4	4	0.53	1.00	0.64
		6	1.53	0.91	0.72
		8	1.15	0.99	0.74
	9	4	0.33	0.97	0.48
		6	0.54	0.97	0.66
		8	0.81	0.97	0.84
		mean SOM	**0.81**	**0.97**	**0.67**
oKMC+	4	4	0.53	0.99	0.87
		6	1.06	0.99	0.87
		8	1.17	1.00	0.91
	9	4	0.29	0.99	0.89
		6	0.47	0.99	0.87
		8	0.56	0.98	0.86
		mean oKMC+	**0.68**	**0.99**	**0.88**

TABLE 2.1 – tableau de comparaison des performances entre les SOM et la combinaison k-means + Sammon mapping (oKMC+) pour différentes configurations de nombre de clusters et de dimensions d'entrée.

À partir des résultats, nous observons que la combinaison k-means + Sammon mapping (oKMC+) a ,en moyenne, des meilleures performances que les SOM :

— un plus faible erreur quadratique moyenne (msqe) pour la quantification vectorielle,
— un indice de Rand plus élevé (qui mesure la similarité entre les partitions) pour la qualité du clustering,
— une corrélation plus forte pour la mesure de la qualité de préservation de la topologie.

Cela montre une limite importante des SOM, leurs performances est inférieure par rapport à des méthodes spécialisées pour la quantification vectorielle et la reduction de dimension. Les resultats suggèrent que les SOM peuvent ne pas être la meilleure option pour des tâches de clustering ou de réduction de dimensionnalité, surtout lorsque la qualité de la quantification ou de la reduction de dimension est cruciale.

2.2.2 Autres limitations

Les SOM présentent d'autres contraintes, notamment l'augmentation de la compléxité computationnelle avec la dimensionnalité des données d'entrée [3]. Lorsque la dimension de la donnée est élevée, le nombre de noeuds dans la grille doit être augmenté pour capturer la complexité des données, ce qui peut entraîner une augmentation significative du temps de calcul et de la mémoire requise pour l'apprentissage du SOM.

En effet, la complexité de l'algorithme d'apprentissage est généralement de l'ordre de $O(n \cdot m \cdot T)$, où n est le nombre d'échantillons d'entrée et m est le nombre de noeuds dans

la grille du SOM (en général $m \ll n$) et T le nombre d'itérations d'apprentissage. Cela le rend moins adapté pour des jeux de données de grande taille ou de forte dimensionnalité [3].

Une autre limitation des SOM est leur incapacité à traiter les données de nature séquentielle ou temporelle. Les SOM classiques ne sont pas conçus pour traiter des données temporelles, ce qui peut limiter leur application dans des domaines tels que la reconnaissance de la parole ou l'analyse de séries temporelles [3].

Ainsi, ces différentes limitations montrent qu'ils peuvent être moins adaptés à certaines applications modernes, notamment dans le domaine de l'apprentissage automatique et de l'analyse de données. C'est pour cela que de nombreuses extensions ont été proposées pour remédier à ces limitations et améliorer les performances des SOM dans différents contextes.

2.3 Extensions

Dans cette section, nous allons parcourir certaines extension qui permettent une amélioration considérable pour ainsi s'adapter à des contextes plus modernes et complexes. Nous allons présenter les extensions suivantes : K-SOM, flow-SOM, hybride SOM (MLP + SOM et CNN + SOM).

2.3.1 Accelerating Stochastique K-SOM

Cette extension, présentée dans [5] propose une approche pour d'accélération d'une autre extension nommée Kernel self-organizing maps (KSOM). K-SOM est une extension des SOM qui utilise des fonctions de noyau pour permettre la modélisation de relations non linéaires entre les données d'entrée et les prototypes du SOM. Cependant, l'apprentissage d'un K-SOM peut être plus coûteux en termes de temps de calcul que celui d'un SOM classique, en particulier pour les grands ensembles de données. Pour avoir une convergeance correcte, l'agorithme d'apprentissage aura besoin de βn itérations, où β est un facteur de proportionnalité pour le nombre d'itérations qui dépend de la complexité du modèle et de la nature des données d'entrée. Cela nous donne une complexité de $O(\beta n^3 \cdot m)$ [5], ce qui peut être prohibitif pour les grands ensembles de données.

L'approche proposée dans [5] consiste à faire un une reformulation des calculs effectués lors des étapes d'affectation et de mise à jour. Elle introduit deux structures intermédiaires : un vecteur A^t et une matrice B^t, qui permettent de stocker des quantités liées aux produits scalaires dans l'espace de Hilbert induit par le noyau. Cela permet d'éviter le recalcul complet des distances entre chaque donnée et les prototypes à chaque itération.

Ainsi la complexité de l'apprentissage est réduit à $O(\beta n^2 \cdot m)$, ce qui est une amélioration significative par rapport à la complexité de l'apprentissage d'un K-SOM classique lors de grands ensembles de données. Cependant, cette extension a besoin d'une mémoire additionnelle pour stocker les structures A^t et B^t. Le tableau 2.2 présente une comparaison des performances entre le K-SOM classique et l'approche accélérée proposée dans [5].

	numeric SOM	rSOM	acc. rSOM
"polblogs"	*NA*	1112.34 (165.86)	**36.99** (4.49)
"cowrie"	*NA*	1715.40 (249.60)	**42.52** (2.32)
"Wine"	**16.40** (2.13)	8527.16 (874.58)	206.32 (38.24)

TABLE 2.2 – Comparaison des temps d'exécution (en secondes) entre le SOM classique, l'approche k-SOM classique (rSOM) et l'approche accélérée (acc. rSOM) proposée dans [5]. Les résultats sont présentés sous la forme de moyenne (écart-type) sur plusieurs exécutions.

Ce tableau montre que l'approche accélérée (acc. rSOM) a des temps d'exécution significativement plus faibles que le K-SOM classique (rSOM) avec un gain de plusieurs ordres de grandeur pour les jeux de données "polblogs" et "cowrie". Cependant, pour les données numériques "Wine", le SOM classique a des temps d'exécution plus faibles que les deux variantes de K-SOM. Cela peut être dû au fait aux manipulations de la matrice des similarités que le K-SOM doit effectuer et qui peuvent être plus coûteuses. L'approche accélérée est particulièrement efficace pour les données non numériques, tandis que pour les données numériques, le SOM classique reste plus rapide.

Ainsi, cette extension est un avencement pour les SOM dans le cadre de données non vectorielles ou complexes, pour lesquelles l'approches classique n'est pas applicables.

2.3.2 FlowSOM

FlowSOM n'est pas vraiment une extension mais une application intéressante utilisée notament dans le domaine de la biologie et plus précisément pour l'analyse de données de cytométrie est le Flow self-organizing maps (FlowSOM) [9]. Cette approche en réalité ne propose pas une nouvelle variante de SOM, mais plutôt une nouvelle manière d'utiliser les SOM pour l'analyse de données de cytométrie avec une structure spécifique. Elle a comme objectif de faciliter la visualisation et l'interprétation des données de cytométrie, au lieu d'utiliser des scatter plots traditionnels, qui peuvent être difficiles à interpréter lorsque nous avons un grand nombre de dimensions et de points de données [9].

Basiquement, flowSOM suit l'algorithme d'apprentissage d'un SOM classique, mais le modèle est intégré dans un pipeline d'analyse de données de cytométrie pour optimiser le clustering, qui comprend des étapes de prétraitement, de clustering et de visualisation.

L'agorithme de flowSOM peut être résumé comme suit [9] :

- **Prétraitement des données** : nettoyage, normalisation et suppression des valeurs aberrantes.
- **Apprentissage du SOM** : un SOM est entraîné afin de projeter les données dans une grille structurée.
- **Construction d'un arbre couvrant minimal (MST)** : les noeuds du SOM sont reliés afin de capturer leur organisation topologique globale.
- **Meta-clustering** : les noeuds du SOM sont regroupés en clusters plus larges à l'aide d'une méthode de clustering.

L'étape de meta-clustering repose sur une sur-segmentation initiale des données via le SOM, où un nombre élevé de prototypes est utilisé pour ainsi capturer des plus petites structures dans les données, puis regrouper en un nombre réduit de clusters plus interprétables. Dans [9] pour avoir le nombre de clusters final, ils utilisent la méthode de l'élbow pour déterminer le nombre optimal de clusters à partir du MST. Elle consiste à detecter le point où la variation de la distance entre les clusters devient moins significative,

cela correspond à un point d'inflexion dans la courbe de la distance entre les clusters en fonction du nombre de clusters.

FlowSOM a montré des performances plus élevées que des méthodes traditionnelles d'analyse de données de cytométrie comme SPADE, notamment en termes de temps de calcul, de qualité de clustering et de visualisation des données. FlowSOM est donc une extension intéressante pour les cartes auto-organisées dans le contexte de l'analyse de données de cytométrie.

Ainsi, cette méthode fusionne les SOM avec d'autres techniques de machine learning formant un pipeline plus large et permettant de répondre efficacement à un domaine d'application spécifique. Cela est aussi le cas avec les SOM hybrides.

2.3.3 SOM Hybrides

Les SOM hybrides sont une extension combinant les cartes auto-organisées avec d'autres techniques d'apprentissage automatique. Nous allons présenter deux type de SOM hybrides : SOM-CNN et SOM-MLP. Il en existe d'autres, mais nous allons nous limiter à ces deux types.

SOM-CNN

Cette extension combine les capacités de représentation des réseaux de neurones convolutionnels (CNN) avec les propriétés de structuration topologique des SOM. Selon les approches, les caractéristiques extraites par le CNN peuvent être utilisées comme entrée d'un SOM pour effectuer un clustering, ou inversement, les sorties d'un SOM peuvent servir d'entrée à un CNN pour des tâches supervisées. Ce type de réseau, employer notament dans l'analyse d'images, utilise l'opération de convolution pour extraire des caractéristiques à partir des données d'entrée, ce qui est particulièrement efficace pour les données structurées en grille, comme les images.

Opération de convolution est définie de manière **discrète** comme suit :

$$(f * g)(t) = \sum_{a=-\infty}^{\infty} f(a) \cdot g(t - a)$$

Où f est la fonction d'entrée (par exemple, une image), g est le noyau de convolution (un petit filtre qui capture des caractéristiques spécifiques), a est l'indice de sommation et t est la position de sortie. Dans le cas des images, cette opération est généralisée en deux dimensions, où le noyau de convolution se déplace sur une grille bidimensionnelle.

Comme pour FlowSOM, cette approche ne propose pas une nouvelle variante de SOM, mais plutôt une nouvelle manière d'utiliser les SOM en les intégrant dans un pipeline d'apprentissage plus large. Le SOM est utilisé pour effectuer un clustering des données et produire une représentation structurée, qui est ensuite exploitée par un modèle supervisé tel qu'un CNN, afin d'améliorer les performances de prédiction.

Dans le document [8], ce type d'approche est testée pour savoir si la présicion de detection de la resistance phénotypique des vecteurs de malaria est améliorée. Les résultats expérimentaux montrent une amélioration des performances en termes de précision de classification par rapport à un CNN seul, suggérant que l'intégration du SOM permet de mieux capturer la structure des données.

SOM-MLP

La combinaison d'un SOM avec un perceptron multicouche (MLP) est une autre approche hybride qui vise à tirer parti des avantages de chaque technique. L'approche du document [11] présente ce modèle hybride pour la prédiction manquante des logs de puits, en se basant sur des similitudes lithofaciques géologiques.

Dans cette architecture, le but du SOM est de est d'organiser les données dans un espace de faible dimension (souvent bidimensionnel) tout en préservant leur structure topologique, et de regrouper les observations similaires en clusters. Cette représentation peut ensuite être utilisée comme entrée d'un modèle supervisé. Le MLP, en tant que réseau de neurones profond capable de modéliser des relations non linéaires complexes, exploite ces informations pour effectuer des tâches de prédiction, telles que l'estimation de valeurs manquantes.

Les résultats expérimentaux montrent que l'approche SOM-MLP permet d'améliorer la précision de prédiction par rapport à des méthodes classiques, notamment dans des contextes où les données présentent une forte hétérogénéité.

Ainsi, certaines extensions de SOM, comme les cartes auto-organisées hybrides, ne se concentrent pas sur l'amélioration de l'algorithme d'apprentissage du SOM lui-même, mais plutôt sur l'intégration avec d'autres techniques d'apprentissage automatique pour créer des pipelines plus puissants et adaptés à des tâches spécifiques. Cet type d'approche permet de concevoir des modèles plus performants et mieux adaptés aux problématiques du monde réel, où les données sont souvent complexes et nécessitent une approche plus intégrée pour l'analyse et la prédiction.

2.3.4 Autres extensions

Nous avons présenté quelques extensions, mais il en existe d'autres, qui essayent de remédier différentes limites des SOM, que ce soit au niveau de la convergence, de la complexité, de la capacité à traiter des données non vectorielles, ou encore de l'intégration avec d'autres modèles d'apprentissage automatique.

Cela est représenté dans le document [3] qui présente une revue complète des principales evolutions des cartes auto-organisées.

Dans la suite de ce rapport, nous allons nous intéresser à l'extension deep embedded self-organizing maps (DESOM) qui mixe les SOM avec une technique moderne d'apprentissage profond : les auto-encodeurs.

2.4 Deep embedded self-organizing maps (DESOM)

L'apprentissage profond est une technique d'apprentissage automatique qui repose sur l'utilisation des réseaux de neurones profonds pour modéliser des relations complexes dans les données. Elle est souvent utilisée pour les tâches supervisées, mais peut àgalement être appliquée pour des tâches non supervisées, notamment à travers les auto-encodeurs (AE). Ces derniers sont des réseaux de neurones conçus pour apprendre une représentation compacte des données d'entrées, appelée espace latent [2].

Cela a conduit à l'emergence des modèles hybrides qui combinent les cartes auto-organisées avec des techniques d'apprentissage profond. L'objectif est de tirer parti à la fois de la capacité de représentation des réseaux profonds et des propriétés topologiques des SOM. Une de ces approches est le Deep Embedded Self-Organizing Maps (DESOM),

qui intègre un auto-encodeur avec un SOM permettant un apprentissage conjoint de la représentation et du clustering [2].

Contrairement aux approches en deux étapes (réduction de dimension puis clustering), DESOM apprend simultanément un espace latent adapté au clustering et les prototypes du SOM. Ce processus permet de construire un espace latent dit SOM-friendly, dans lequel les données sont organisées de manière plus cohérente pour la quantification et la préservation de la topologie [2]. Le SOM agit ainsi comme une forme de régularisation qui améliore la structure topologique et la qualité du clustering dans cet espace latent.

Dans la suite de ce rapport, nous allons présenter les principes de fonctionnement de DESOM, son architecture et son algorithme d'apprentissage.

2.4.1 Autoencodeur (AE)

Les auto-encodeurs sont des réseaux de neurones conçus pour la reconstruction des données d'entrée de manière non supervisée dont l'objectif est de reconstruire les données d'entrée tout en apprenant une représentation compacte de celles-ci. Ils permettent ainsi d'extraire des caractéristiques pertinentes en minimisant la perte d'information entre l'entrée et sa reconstruction.

Un AE est composé de deux parties principales : un encodeur, qui transforme les données d'entrée x en une représentation de plus faible dimension appelée espace latent z, et un décodeur, qui reconstruit les données d'entrée à partir de cette représentation latente [2]. L'architecture d'un AE est illustrée à la figure 2.3.

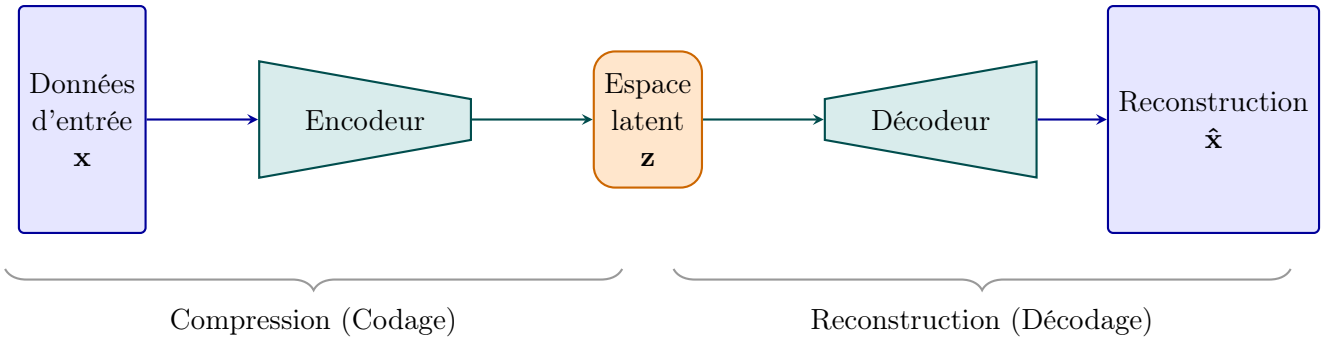


FIGURE 2.3 – Architecture générale d'un autoencodeur. L'encodeur compresse les données d'entrée dans un espace latent (goulot d'étranglement), tandis que le décodeur effectue l'opération inverse pour reconstruire $\mathbf{x}$.

Pour que le modèle puisse produire un espace latent de qualité, le modèle est entraîné en minimisant une fonction de perte qui mesure la différence entre les données d'entrée et leur reconstruction. Pour le DESOM, l'AE choisi apartient à la famille des auto-encodeur sous-complets (undercomplete autoencoder), qui impose une contrainte de dimensionnalité sur l'espace latent, c'est à dire que la dimension de l'espace latent est inférieure à celle des données d'entrée. Cette contrainte force au modèle à apprendre une réprésentation compréssée et évite que le modèle puisse utiliser la fonction d'identité pour la reconstruction [2].

Il existe d'autres types d'auto-encodeurs, comme les AE variationnels (VAE) qui introduisent une modélisation probabilistes de l'espace latent. Cependant, dans ce travail, nous nous concentrerons uniquement sur les AE deterministes produisant un espace latent continu.

2.4.2 Architecture du DESOM

L'architecture du DESOM présentée dans [2] repose sur la combinaison d'un auto-encodeur et d'une carte auto-organisée. L'objectif est d'intégrer le SOM dans l'architecture de l'auto-encodeur de manière à avoir un apprentissage conjoint d'une représentation latente des données et une organisation topologique de cette représentation.

L'AE prend les données d'entrée x et les encode dans un espace latent z, qui est ensuite utilisé comme entrée pour le SOM. La couche SOM est entrainée à organiser les noeuds du SOM dans cet espace latent. L'architecture du DESOM est illustrée à la figure 2.4.

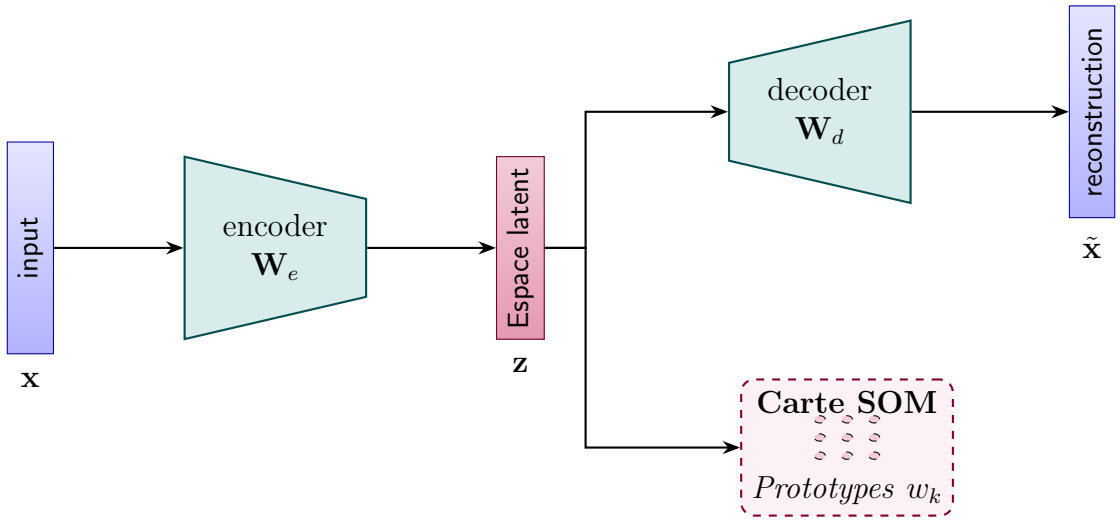


FIGURE 2.4 – Architecture du DESOM inspirée du document [2]. Les flèches noires indiquent la propagation avant (forward pass). L'encodeur $\mathbf{W}_e$ apprend à encoder les données d'entrée $\mathbf{x}$ dans un espace latent $\mathbf{z}$, qui est ensuite utilisé par le décodeur $\mathbf{W}_d$, pour la reconstruction de $\mathbf{x}$ et par le SOM pour l'apprentissage de la structure topologique et du clustering.

Cette architecture permet un réduction du temps moyen d'apprentissage par rapport à une approche en deux étapes, où nous entraînerons d'abord un auto-encodeur, puis un SOM sur les représentations apprises [2]. Le DESOM optimise simultanément les poids de l'autoencodeur et les prototypes de la carte. Cette optimisation conjointe permet d'obtenir un espace latent plus adapté à l'organisation topologique et au clustering.

Son algorithme d'apprentissage doit donc optimiser à la fois la fonction de perte de reconstruction de l'auto-encodeur et la fonction de perte du SOM en utilisant la méthode de descente de gradient.

2.4.3 Fonction de perte du DESOM

Le rôle de la fonction de perte dans le DESOM est central pour l'apprentissage conjoint de la représentation latente et de la carte auto-organisée. La fonction de perte du DESOM, $\mathcal{L}_{\text{DESOM}}$, est une combinaison de deux composantes principales : la perte de reconstruction de l'AE, $\mathcal{L}_{\text{R}}$, et la perte du SOM, $\mathcal{L}_{\text{SOM}}$ [2]. Il faut donc définir explicitement $\mathcal{L}_{\text{SOM}}$.

Pour un SOM classique, soit $\mathcal{L}^i_{\text{SOM}}$ la fonction de perte du SOM pour un échantillon d'entrée x_i, avec w_{c_i} comme son noeud gagant (BMU). Alors, la fonction de perte du SOM

pour cet échantillon est donnée par :

$$\mathcal{L}^i_{\text{SOM}}(x_i, \{w_k\}) = \sum_{k=1}^{m} h_{c_i k} \cdot \|x_i - w_k\|^2$$

Cette expression est donc la somme des distances au carré entre x_i et les prototypes, où c_i est l'indice du BMU pour l'échantillon x_i, $h_{c_i k}$ est la fonction de voisinage entre w_k et le BMU.

Donc, la fonction de perte d'un SOM de manière générale est donnée par :

$$\mathcal{L}_{\text{SOM}} = \sum_{i=1}^{n} \mathcal{L}^i_{\text{SOM}}(x_i, c_i, \{w_k\}) \Leftrightarrow$$

$$\mathcal{L}_{\text{SOM}} = \sum_{i=1}^{n} \sum_{k=1}^{m} h_{c_i k} \cdot \|x_i - w_k\|^2$$

La seconde composante pour $\mathcal{L}_{\text{DESOM}}$ est la fonction de perte de reconstruction $\mathcal{L}_{\text{R}}$ de l'auto-encodeur.

Soit W_e les poids de l'encodeur, W_{de} les poids du décodeur, $x_i \in \mathbb{R}^d$ les données d'entrée et $\tilde{x}_i \in \mathbb{R}^d$ la reconstruction de x_i par l'auto-encodeur, notons $f_{W_e} : \mathbb{R}^d \to \mathbb{R}^L$ la fonction d'encodage et $g_{W_{de}} : \mathbb{R}^L \to \mathbb{R}^d$ la fonction de décodage, avec $z_i = f_{W_e}(x_i)$ et $\tilde{x}_i = g_{W_{de}}(z_i)$. La fonction de perte de reconstruction $\mathcal{L}_{\text{R}}$ est généralement définie comme la moyenne de l'erreur quadratique (MSE) [2] :

$$\mathcal{L}_{\text{R}}(W_e, W_{de}) = \frac{1}{n} \sum_{i=1}^{n} \mathcal{L}^i_{\text{R}} = \frac{1}{n} \sum_{i=1}^{n} \|x_i - \tilde{x}_i\|^2 \Leftrightarrow$$

En remplaçant $\tilde{x}_i$ par son expression, on obtient :

$$\mathcal{L}_{\text{R}}(W_e, W_{de}) = \frac{1}{n} \sum_{i=1}^{n} \|x_i - g_{W_{de}}(f_{W_e}(x_i))\|^2$$

Finalement, avec les deux fonctions de perte, nous pouvons définir la fonction de perte hybride du DESOM [2] :

$$\mathcal{L}_{\text{DESOM}}(W_e, W_{de}, \{w_k\}) = \mathcal{L}_{\text{R}}(W_e, W_{de}) + \gamma \mathcal{L}_{\text{SOM}}(W_e, \{w_k\})$$

Il est important de noter que la fonction de perte du SOM, $\mathcal{L}_{\text{SOM}}$, dépend à la fois des poids de l'encodeur W_e et les poids w_k de ses noeuds. Ces données d'entrée ne sont plus les données d'origine x_i, mais plutôt les représentations latentes $z_i \in \mathbb{R}^L$. Nous aurons donc pour un noeud S_i son vecteur de poids $w_i \in \mathbb{R}^L$.

Le paramètre γ est un hyperparamètre qui équilibre l'importance relative de la perte de reconstruction et de la perte du SOM lors de l'apprentissage conjoint du DESOM. Une valeur élevée de γ donne plus d'importance à l'organisation topologique et au clustering dans l'espace latent, tandis qu'une valeur plus faible privilégie la qualité de reconstruction de l'autoencodeur.

Ainsi, la fonction de perte du SOM agit comme une régularisation guidée par la carte auto-organisatrice : elle encourage l'encodeur à produire un espace latent adapté à la quantification vectorielle et à la préservation de la topologie.

2.4.4 Processus d'apprentissage

Comme mentionné précédemment, l'apprentissage du DESOM est un processus conjoint qui optimise simultanément les poids de l'auto-encodeur et les noeuds du SOM. L'objectif est de minimiser la fonction de perte globale :

$$\mathcal{L}_{DESOM} = \mathcal{L}_R + \gamma \mathcal{L}_{SOM}$$

Cette optimisation permet à l'autoencodeur d'apprendre une représentation latente informative, tout en contraignant cet espace latent à être adapté à l'organisation topologique du SOM (SOM-friendly).

Pour effectuer cette optimisation il faut calculer les gradients de $\mathcal{L}_{\text{DESOM}}$ par rapport aux poids de l'encodeur W_e, du décodeur W_{de} et des noeuds du SOM $\{w_k\}$. Cependant, le calcul du BMU (via l'opération d'argmin) dont dépend la fonction de voisinage n'est pas différentiable. Pour remédier ce problème, nous considérons $h_{c_i k}$ comme des coefficients constants à chaque étape d'optimisation [2].

Cette contrainte, nous permet d'utiliser la rétropropagation et la descente de gradient pour mettre à jour les paramètres du modèle.

Les gradients de perte globale s'ecrivent alors [2] :

$$\begin{aligned}
\frac{\partial \mathcal{L}_{\text{DESOM}}}{\partial W_e} &= \frac{\partial \mathcal{L}_{\text{R}}}{\partial W_e} + \gamma \frac{\partial \mathcal{L}_{\text{SOM}}}{\partial W_e} \\
\frac{\partial \mathcal{L}_{\text{DESOM}}}{\partial W_{de}} &= \frac{\partial \mathcal{L}_{\text{R}}}{\partial W_{de}} \\
\frac{\partial \mathcal{L}_{\text{DESOM}}}{\partial w_k} &= \gamma \frac{\partial \mathcal{L}_{\text{SOM}}}{\partial w_k}
\end{aligned}$$

En calculant pour un point de données x_i, les gradients associés à la perte de reconstruction sont donnés par :

$$\begin{aligned}
\frac{\partial \mathcal{L}^i_{\text{R}}}{\partial W_e} &= 2(g_{W_{de}}(f_{W_e}(x_i)) - x_i) \frac{\partial g_{W_{de}}(f_{W_e}(x_i))}{\partial W_e} \\
\frac{\partial \mathcal{L}^i_{\text{R}}}{\partial W_{de}} &= 2(g_{W_{de}}(f_{W_e}(x_i)) - x_i) \frac{\partial g_{W_{de}}(f_{W_e}(x_i))}{\partial W_{de}}
\end{aligned}$$

Les gradients associés à la perte SOM sont :

$$\begin{aligned}
\frac{\partial \mathcal{L}^i_{\text{SOM}}}{\partial W_e} &= 2 \sum_{k=1}^{m} h_{c_i k}(f_{W_e}(x_i) - w_k) \frac{\partial f_{W_e}(x_i)}{\partial W_e} \\
\frac{\partial \mathcal{L}^i_{\text{SOM}}}{\partial w_k} &= 2 h_{c_i k}(w_k - f_{W_e}(x_i))
\end{aligned}$$

Avec ces gradients, nous pouvons mettre à jour les poids de l'encodeur, du décodeur et des prototypes du SOM à chaque itération de l'apprentissage à l'aide d'une descente de gradient stochastique par mini-batch [2]. Soit β un mini-batch de n_b échantillons et η le taux d'apprentissage. Les règles de mise à jour pour l'encodeur et le décodeur sont alors

données par :

$$W_e \leftarrow W_e - \frac{\eta}{n_b} \sum_{i \in \beta} \left(\frac{\partial \mathcal{L}_{\mathrm{R}}^i}{\partial W_e} + \gamma \frac{\partial \mathcal{L}_{\mathrm{SOM}}^i}{\partial W_e} \right)$$

$$W_{de} \leftarrow W_{de} - \frac{\eta}{n_b} \sum_{i \in \beta} \frac{\partial \mathcal{L}_{\mathrm{R}}^i}{\partial W_{de}}$$

La règle de mise à jour pour les prototypes du SOM est donnée par [2] :

$$w_k \leftarrow w_k - \frac{\eta}{n_b} \sum_{i \in \beta} \gamma \frac{\partial \mathcal{L}_{\mathrm{SOM}}^i}{\partial w_k}$$

En développant $\frac{\partial \mathcal{L}_{\mathrm{SOM}}^i}{\partial w_k}$ avec

$$z_i = f_{W_e}(x_i)$$

La règle de mise à jour devient :

$$w_k \leftarrow w_k + \frac{2\eta\gamma}{n_b} \sum_{i \in \beta} h_{c_i k}(z_i - w_k)$$

Cette règle montre que chaque noeuds est déplacé vers les représentations latentes du mini-batch, avec une intensité pondérée par la fonction de voisinage du SOM.

Ces mis à jour sont utilisées pour la rétropropagation de l'erreur à travers le réseau. L'encodeur reçoit le signal provenant de la reconstruction et le signal provenant de la contrainte SOM, tandis que le décodeur et les noeuds du SOM sont mis à jour respectivement à partir la perte de reconstruction et de la perte SOM. La figure 2.5 illustre ce processus d'apprentissage conjoint.

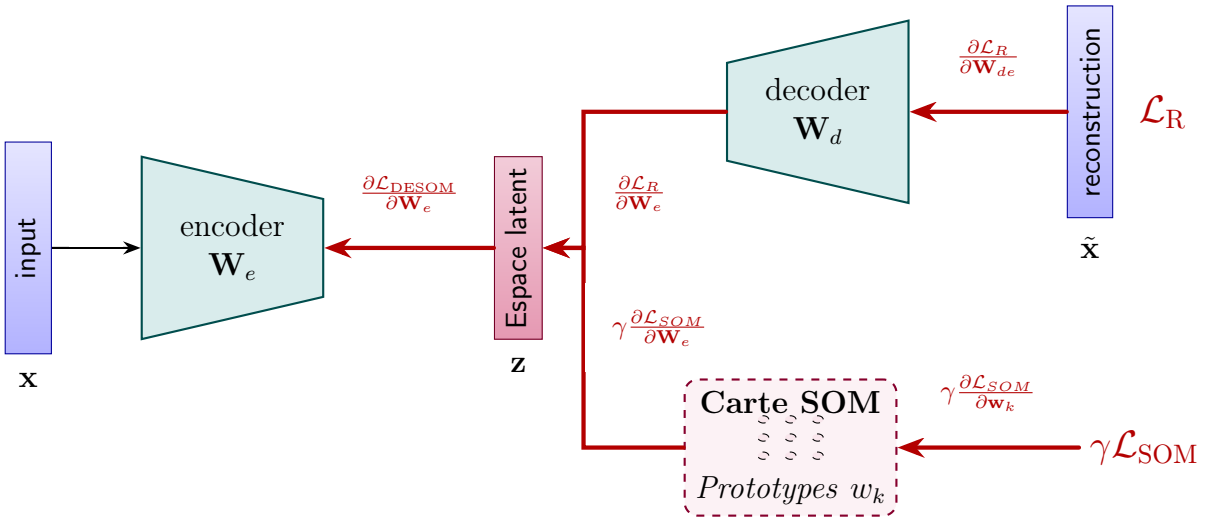


FIGURE 2.5 – Processus de rétropropagation (backward pass) du DESOM. Les flèches rouges indiquent le flux des gradients. Les poids de l'encodeur $\mathbf{W}_e$ sont mis à jour en fonction des erreurs combinées provenant de la reconstruction ($\mathcal{L}_{\mathrm{R}}$) et de l'organisation topologique du SOM ($\mathcal{L}_{\mathrm{SOM}}$). Les flèches noires indiquent la propagation avant (forward pass) pour la cohérence visuelle.

Donc la minimisation se produit via une descente de gradient stochastique comme c'est le cas dans le modèle de SOM stochastique [2].

L'algorithme 3 présente une description détaillée du processus d'apprentissage du DESOM. Les affectations aux BMU et les coefficients de voisinage sont considérés comme constants lors du calcul des gradients à chaque itération.

Algorithm 3 Algorithme d'apprentissage du DESOM

Require: Données d'entrée $\{x_i\}_{i=1}^{n}$, nombre de prototypes m, taux d'apprentissage η, hyperparamètre de régularisation γ, nombre d'itérations T.

Initialiser les poids de l'encodeur W_e, du décodeur W_{de} et des prototypes du SOM $\{w_k\}_{k=1}^{m}$ de manière aléatoire.
for $t = 1$ to T **do**
    Sélectionner un mini-batch β de n_b échantillons de données d'entrée.
    for chaque échantillon x_i dans le mini-batch β **do**
        Calculer la représentation latente $z_i = f_{W_e}(x_i)$.
        Trouver le BMU $c_i = \arg\min_k \|z_i - w_k\|^2$.
        Calculer les coefficients de voisinage $h_{c_i,k}$ pour chaque prototype w_k.
        Calculer la reconstruction $\tilde{x}_i = g_{W_{de}}(z_i)$.
        Calculer les pertes $\mathcal{L}_R^i$ et $\mathcal{L}_{SOM}^i$
    end for
    Calculer la fonction de coût totale du mini-batch :
    $\mathcal{L}_{\text{DESOM}} = \frac{1}{n_b} \sum_{x_i \in \beta} (\mathcal{L}_{\text{R}}^i + \gamma \mathcal{L}_{\text{SOM}}^i)$
    Calculer les gradients de $\mathcal{L}_{DESOM}^{\beta}$ par rétropropagation.
    Mettre à jour W_e, W_{de} et $\{w_k\}_{k=1}^{m}$ par descente de gradient stochastique à mini-batch.
end for

Ainsi, cet algorithme fournit une description du processus d'apprentissage du DESOM. Cette méthode intégre le SOM dans l'architecture de l'auto-encodeur, en prenant les représentations latentes produite par l'encodeur comme entrée pour le SOM, rendant ainsi l'espace d'entrée SOM-friendly. Cette contrainte encourage l'apprentissage d'un espace latent qui améliore la qualité du clustering et la préservation de la topologie.

Chapitre 3

Etude empirique

Ce chapitre consistera à la comparaison des performances dans certains jeux de données entre un SOM implémenté depuis zéro, SOM d'une librairie et un DESOM implémenté à l'aide de la librairie PyTorch [**?**].

3.1 Données utilisées

3.2 SOM de base

3.3 DESOM

3.4 Comparaison et analyse des résultats

Modèle	QE	TE	Pureté	NMI	Grille
SOM	5.266000	0.436000	0.794000	0.529000	10x10
AE+SOM	1.296000	0.473000	0.834000	0.543000	10x10
DESOM	0.247000	0.604000	0.843000	0.553000	10x10

Chapitre 4

Conclusion

Bibliographie

[1] Arthur Flexer. Limitations of self-organizing maps for vector quantization and multidimensional scaling, 1996.

[2] Florent Forest, Mustapha Lebbah, Hanene Azzag, Jérôme Lacaille. Deep embedded self-organizing maps for joint representation learning and topology-preserving clustering, 2021.

[3] Axel Guérin, Pierre Chauvet, and Frédéric Saubion. A survey on recent advances in self-organizing maps, 2024.

[4] Hornik, K. Approximation capabilities of multilayer feedforward networks, 1991.

[5] Jérôme J. Mariette, Fabrice Rossi, Madalina Olteanu, Nathalie Villa-Vialaneix. Accelerationg stochastic kernel som, 2020.

[6] Teuvo Kohonen. The self-organizing map, 1990.

[7] Teuvo Kohonen. Essentials of the self-organizing map, 2012.

[8] Komi Mensah Agboka, Elfatih M. Abdel-Rahmana, Daisy Salifu, Brian Kanji, Frank T. Ndjomatchoua, Ritter A.Y. Guimapi, Sunday Ekesi, Landmann Tobias. Towards combining self-organizing maps (som) and convolutional neural network (cnn) for improving model accuracy : Application to malaria vectors phenotypic resistance, 2025.

[9] Sofie Van Gassen, Britt Callebaut, Mary J. Van Helden, Bart N. Lambrecht, Piet Demeester, Tom Dhaene, Yvan Saeys. Flowsom : Using self-organizing maps for visualization and interpretation of cytometry data, 2015.

[10] Stephane Marchand-Maillet. Intelligence artificielle, 2026.

[11] Wakeel Hussain, Miao Luo, Muhammad Ali, Izhar Sadiq, Erasto E. Kasala, Tariq Aziz, Zuriyat Batool. Hybrid modeling of deep neural networks and unsupervised machine learning algorithms for missing well log prediction based on geological lithofacies similarities, 2025.

[12] Wikipedia contributors. Neurona, 2025.

[13] Wikipedia contributors. Artificial neuron, 2026.

[14] Wikipedia contributors. Dirac delta function, 2026.